

# Cheatsheet WuS

Nicolas Wehrli

June 2023

## 1 Grundbegriffe

### 1.1 Wahrscheinlichkeitsraum

#### Axiome von Kolmogorov

Das Tuple  $(\Omega, \mathcal{A}, \mathbb{P})$  ist ein **Wahrscheinlichkeitsraum** mit

I. **Grundraum**  $\Omega$  mit  $\Omega \neq \emptyset$ , wobei  $\omega \in \Omega$  ein Elementarereignis ist.

II.  **$\sigma$ -Algebra**  $\mathcal{A} \subseteq \mathcal{P}(\Omega)$  wobei gilt:

1.  $\Omega \in \mathcal{A}$
2.  $A \in \mathcal{A} \implies A^c \in \mathcal{A}$
3.  $A_1, A_2, \dots \in \mathcal{A} \implies \bigcup_i A_i \in \mathcal{A}$

III. **Wahrscheinlichkeitsmass**  $\mathbb{P}$  auf  $(\Omega, \mathcal{A})$  ist eine Abbildung  $\mathbb{P} : \mathcal{A} \mapsto [0, 1]$ , wobei gilt:

1.  $\mathbb{P}(\Omega) = 1$
2.  $A_1, A_2, \dots \in \mathcal{A}, \forall i \neq j : A_i \cap A_j = \emptyset \implies \mathbb{P}(\bigcup_i A_i) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$

#### De-Morgan

Sei  $(A_i)_{i \geq 1}$  eine Folge von beliebigen Mengen. Dann gilt

$$\left( \bigcup_{i=1}^{\infty} A_i \right)^c = \bigcap_{i=1}^{\infty} (A_i)^c$$

Daraus folgt

1.  $A_1, A_2, \dots \in \mathcal{A} \implies \bigcap_{i=1}^{\infty} A_i \in \mathcal{A}$
2.  $A, B \in \mathcal{A} \implies (A \cup B), (A \cap B) \in \mathcal{A}$

und für  $A, B \in \mathcal{A}$

1.  $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
2.  $A \subseteq B \implies \mathbb{P}(A) \leq \mathbb{P}(B)$
3.  $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$

Sei  $A_1, A_2, \dots \in \mathcal{A}$ , dann gilt:

#### Union Bound

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) \leq \sum_{i=1}^{\infty} \mathbb{P}(A_i)$$

#### Siebformel

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(A_{i_1} \cap \dots \cap A_{i_k})$$

#### Atome

Sei  $\Omega$  nicht leer und diskret. Sei  $\mathcal{F}$  eine beliebige  $\sigma$ -Algebra über  $\Omega$ .

Eine nichtleere Menge  $A \in \mathcal{F}$  heisst **atomare** Menge von  $\mathcal{F}$  falls für alle  $B \in \mathcal{F}$  gilt:

$$B \subseteq A \implies B = \emptyset \vee B = A$$

(Intuitiv:  $A$  ist die kleinste nichtleere Menge bezüglich der Inklusion in  $\mathcal{F}$ )

Die Menge der atomaren Mengen von  $\mathcal{F}$  bezeichnen wir mit  $\text{Atom}(\mathcal{F})$ .

Jedes Element von  $\mathcal{F}$  lässt sich als abzählbare Vereinigung von Elementen aus  $\text{Atom}(\mathcal{F})$  schreiben.

## 1.2 Bedingte Wahrscheinlichkeiten

Sei  $(\Omega, \mathcal{A}, \mathbb{P})$  ein Wahrscheinlichkeitsraum.

#### Bedingte Wahrscheinlichkeit

Sei  $A, B \in \mathcal{A}$  und  $\mathbb{P}(B) > 0$ , dann ist die **bedingte Wahrscheinlichkeit von  $A$  gegeben  $B$**

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}$$

#### Satz der totalen Wahrscheinlichkeit

Sei  $(B_i)_{i \in I}$  eine Partition von  $\Omega$ . Dann gilt für jedes beliebige  $A \in \mathcal{A}$

$$\mathbb{P}(A) = \sum_{i: \mathbb{P}(B_i) > 0} \mathbb{P}(A|B_i) \mathbb{P}(B_i)$$

#### Satz von Bayes

Aus der Definition der bedingten W'keit folgt sofort die Bayessche Formel, welche den Zusammenhang zwischen  $\mathbb{P}(A|B)$  und  $\mathbb{P}(B|A)$  beschreibt:

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A|B) \mathbb{P}(B)}{\mathbb{P}(A)}$$

Mit dem **Satz der totalen W'keit** können wir  $\mathbb{P}(A)$  umschreiben und kommen auf folgende Form:

Sei  $(B_i)_{i \in I}$  eine **Partition** von  $\Omega$ . Dann gilt für jedes beliebige  $A \in \mathcal{A}, \mathbb{P}(A) > 0$

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A|B_i) \cdot \mathbb{P}(B_i)}{\sum_{j: \mathbb{P}(B_j) > 0} \mathbb{P}(A|B_j) \cdot \mathbb{P}(B_j)}$$

#### Intuition Bayessche Statistik

In dieser Form würde man  $A$  als das **eingetretene Ereignis** und die  $B_i$  als die verschiedene **Hypothesen** verstehen.

In der Bayesschen Statistik versucht man die Hypothese zu finden, so dass  $\mathbb{P}(B_i|A)$  **maximiert** wird.

(Wurde in der Vorlesung nicht weiter behandelt)

## 1.3 Unabhängigkeit

#### Unabhängigkeit von zwei Ereignissen

Zwei Ereignisse  $A, B \in \mathcal{A}$  heissen **unabhängig**, wenn

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$$

- $\mathbb{P}(A) \in \{0, 1\} \implies A$  zu jedem Ereignis unabhängig
- $A$  zu sich selbst unabhängig  $\implies \mathbb{P}(A) \in \{0, 1\}$
- $A, B$  unabhängig  $\implies A, B^c$  unabhängig

Wenn  $\mathbb{P}(A) > 0, \mathbb{P}(B) > 0$  gilt:

$$A, B \text{ unabhängig} \iff \mathbb{P}(A|B) = \mathbb{P}(A) \iff \mathbb{P}(B|A) = \mathbb{P}(B)$$

Wir können die Definition der Unabhängigkeit auf beliebige Mengen von Ereignissen erweitern.

#### Allgemeine Unabhängigkeit

Eine Kollektion von Ereignissen  $(A_i; i \in I)$  heisst (**stochastisch**) **unabhängig**, wenn

$$J \subseteq I \text{ endlich} \implies \mathbb{P}\left(\bigcap_{i \in J} A_i\right) = \prod_{i \in J} \mathbb{P}(A_i)$$

## 2 Zufallsvariablen

Sei  $(\Omega, \mathcal{A}, \mathbb{P})$  ein diskreter Wahrscheinlichkeitsraum.

#### Zufallsvariable

Eine (reellwertige) **Zufallsvariable** auf  $\Omega$  ist eine messbare Funktion  $X : \Omega \rightarrow \mathbb{R}$ .

$$X : \Omega \rightarrow \mathbb{R} \text{ messbar} \iff \forall x \in \mathbb{R} : X^{-1}(\{x\}) \in \mathcal{A}$$

Die Eigenschaft **messbar** ist bezüglich dem Wahrscheinlichkeitsmass  $\mathbb{P}$  relevant (i.e. dann ist  $\mathbb{P}(X = x) := \mathbb{P}(\{\omega \in \Omega \mid X(\omega) = x\})$  wohldefiniert).

Diese Definition von **messbar** ist für diskrete  $\Omega$  äquivalent zu derjenigen der Vorlesung, die die rechte Seite vom '  $\iff$  ' für alle abgeschlossenen Teilmengen  $B \subset \mathbb{R}$  fordert.

Für die Messbarkeit von  $X$  ist nur  $X(\Omega) \subseteq \mathbb{R}$  entscheidend und jede Teilmenge  $A \subseteq X(\Omega)$  ist abzählbar (da  $\Omega$  abzählbar). Somit kann  $X^{-1}(A)$  als abzählbare Vereinigung von  $\bigcup_{x \in A} X^{-1}(\{x\})$  geschrieben werden.

( $\implies X^{-1}(A) \in \mathcal{A}$  per Def.  $\sigma$ -Algebra)

### 2.1 Verteilungsfunktion

Die **Verteilungsfunktion** ist die Abbildung  $F_X : \mathbb{R} \rightarrow [0, 1]$  definiert durch:

$$F_X(t) := \mathbb{P}(X \leq t), \forall t \in \mathbb{R}$$

Die Funktion erfüllt folgende Eigenschaften:

- 1.  $F_X$  ist monoton wachsend
- 2.  $F_X$  ist rechtsstetig, i.e.  $\lim_{h \downarrow 0} F_X(x+h) = F_X(x)$
- 3.  $\lim_{x \rightarrow -\infty} F_X(x) = 0$  und  $\lim_{x \rightarrow \infty} F_X(x) = 1$
- 4.  $\forall a, b \in \mathbb{R}, a < b: \mathbb{P}(a < X \leq b) = F_X(b) - F_X(a)$

**Linksstetigkeit**

Die Verteilungsfunktion ist nicht immer linksstetig.

Sei  $F_X(a-) := \lim_{h \downarrow 0} F_X(a-h)$  für  $a \in \mathbb{R}$  beliebig.

Dann gilt:

$$\mathbb{P}(X = a) = F_X(a) - F_X(a-)$$

Intuitiv folgt daraus

- Wenn  $F_X$  in einem Punkt  $a \in \mathbb{R}$  nicht stetig ist, dann ist die "Sprunghöhe"  $F_X(a) - F_X(a-)$  gleich der Wahrscheinlichkeit  $\mathbb{P}(X = a)$ .
- Falls  $F_X$  stetig in einem Punkt  $a \in \mathbb{R}$ , dann gilt  $\mathbb{P}(X = a) = 0$ .

**Unabhängigkeit von Zufallsvariablen**

Seien  $X_1, \dots, X_n$  Zufallsvariablen auf einem Wahrscheinlichkeitsraum  $(\Omega, \mathcal{A}, \mathbb{P})$ . Dann heissen  $X_1, \dots, X_n$  **unabhängig**, falls

$\forall x_1, \dots, x_n \in \mathbb{R} :$

$\mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) = \mathbb{P}(X_1 \leq x_1) \cdot \dots \cdot \mathbb{P}(X_n \leq x_n)$ .

**Unendlich viele Bernoulli-Experimente**

TBD

2.2 Diskrete Zufallsvariablen

Sei  $A \in \mathcal{F}$  ein Ereignis.

Wir sagen  $A$  tritt **fast sicher (f.s.)** ein, falls  $\mathbb{P}(A) = 1$ .

Seien  $X, Y : \Omega \rightarrow \mathbb{R}$  Zufallsvariablen:

$X \leq Y$  f.s.  $\iff \mathbb{P}(X \leq Y) = 1$

**Diskrete Zufallsvariable**

Eine Zufallsvariable  $X : \Omega \rightarrow \mathbb{R}$  heisst **diskret**, falls eine endliche oder abzählbare Menge  $W \subset \mathbb{R}$  existiert, sodass

$\mathbb{P}(X \in W) = 1$

Falls  $\Omega$  endlich oder abzählbar ist, dann ist  $X$  immer diskret.

Die **Verteilungsfunktion** einer diskreten ZV  $X$ :

$$F_X(x) = \mathbb{P}(X \leq x) = \sum_{y \in W} p(y) \cdot \mathbb{1}_{y \leq x}$$

Die **Gewichtsfunktion** einer diskreten ZV  $X$ :

$\forall x \in X(\Omega) : p(x) = \mathbb{P}(X = x)$  wobei  $\sum_{x \in X(\Omega)} p(x) = 1$

2.3 Diskrete Verteilungen

**Bernoulli-Verteilung** ( $X \sim \text{Ber}(p)$ ):

$X(\Omega) = \{0, 1\}$  und die Gewichtsfunktion ist definiert durch

$p(1) := \mathbb{P}(X = 1) = p$  und  $p(0) := \mathbb{P}(X = 0) = 1 - p$ .

**Binomialverteilung** ( $X \sim \text{Bin}(n, p)$ ):

Wiederholung von  $n$  unabhängigen Bernoulli-Experimenten mit gleichem Parameter  $p$ .

$p(k) := \mathbb{P}(X = k) = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k} \quad \forall k \in \{0, 1, \dots, n\}$

**Geometrische Verteilung** ( $X \sim \text{Geo}(p)$ ):

Warten auf den 1-ten Erfolg.

$p(k) := \mathbb{P}(X = k) = (1-p)^{k-1} \cdot p \quad \forall k \in \mathbb{N} \setminus \{0\}$

**Poisson-Verteilung** ( $X \sim \text{Poisson}(\lambda)$ ):

Grenzwert der Binomialverteilung für grosse  $n$  und kleine  $p$ .

$p(k) := \mathbb{P}(X = k) = \frac{\lambda^k}{k!} \cdot e^{-\lambda} \quad \forall k \in \mathbb{N}_0, \lambda > 0$

- 1. Für  $X_n \sim \text{Bin}(n, \frac{\lambda}{n})$  gilt  $\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \mathbb{P}(Y = k)$  wobei  $Y \sim \text{Poisson}(\lambda)$ .
- 2. Seien  $X_1 \sim \text{Poisson}(\lambda_1)$  und  $X_2 \sim \text{Poisson}(\lambda_2)$  unabhängig. Dann gilt  $(X_1 + X_2) \sim \text{Poisson}(\lambda_1 + \lambda_2)$ .

2.4 Stetige Zufallsvariablen

**Stetige Zufallsvariablen, Dichte**

Eine Zufallsvariable  $X : \Omega \rightarrow \mathbb{R}$  heisst **stetig**, wenn ihre Verteilungsfunktion  $F_X$  wie folgt geschrieben werden kann

$F_X(a) = \int_{-\infty}^a f(x) dx =$  für alle  $a \in \mathbb{R}$ .

wobei  $f : \mathbb{R} \rightarrow \mathbb{R}^+$  eine nicht-negative Funktion ist.  $f$  wird dann als **Dichte** von  $X$  benannt.

Wenn  $f : (\mathbb{R}, \mathcal{B}) \rightarrow (\mathbb{R}, \mathcal{B})$  messbar ist, ist die Zufallsvariable  $X$  **absolut stetig**.

**Intuition:**  $f(x) dx$  ist die Wahrscheinlichkeit, dass  $X \in [x, x + dx]$ .

**Von  $F_X$  zu  $f$ :**

Sei  $X$  eine Zufallsvariable mit stetiger Verteilungsfunktion  $F_X$  und  $F_X$  stückweise  $\mathcal{C}^1$ , d.h. es gibt  $x_0 = -\infty < \dots < x_{n-1} < x_n = +\infty$ , sodass  $F_X$  auf jedem Intervall  $(x_i, x_{i+1})$  Element von  $\mathcal{C}^1$  ist. Dann ist  $X$  eine stetige Zufallsvariable und die Dichte  $f$  kann wie folgt konstruiert werden:

$\forall x \in (x_i, x_{i+1}) \quad f(x) = F_X'(x)$ .

**TODO: Beispielrechnung -Dichte finden**

2.5 Stetige Verteilungen

**Gleichverteilung** ( $X \sim \mathcal{U}([a, b])$ ):

Die Dichte ist auf dem Intervall  $[a, b]$  gleich.

$f_{a,b}(x) = \begin{cases} 0 & x \notin [a, b] \\ \frac{1}{b-a} & x \in [a, b] \end{cases}$

**Exponentialverteilung** ( $T \sim \text{Exp}(\lambda)$ ):

Lebensdauer oder Wartezeit eines allg. Ereignisses (Stetiges Äquivalent zur Geometrischen Verteilung).

$f_\lambda(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0, \\ 0 & x < 0. \end{cases}$

**Normalverteilung** ( $X \sim \mathcal{N}(m, \sigma^2)$ ):

Häufig verwendete Verteilung. undefiniert für  $\sigma = 0$ .

$f_{m,\sigma}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}$

- 1. Seien  $X_1, \dots, X_n$  **unabhängige** normalverteilte ZV mit Parametern  $(m_1, \sigma_1^2), \dots, (m_n, \sigma_n^2)$ , dann ist

$Z = m_0 + \lambda_1 X_1 + \dots + \lambda_n X_n$

eine normalverteilte ZV mit Parametern  $m = m_0 + \lambda_1 m_1 + \dots + \lambda_n m_n$  und  $\sigma^2 = \lambda_1^2 \sigma_1^2 + \dots + \lambda_n^2 \sigma_n^2$ .

- 2. Sei  $Z \sim \mathcal{N}(0, 1)$  eine **standardnormalverteilte** Zufallsvariable. Dann gilt für  $X \sim \mathcal{N}(m, \sigma^2)$

$X = m + \sigma \cdot Z$

3 Erwartungswert

**Erwartungswert - Diskrete ZV**

Sei  $X : \Omega \rightarrow \mathbb{R}$  eine diskrete Zufallsvariable,  $W_X := X(\Omega)$  und  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  eine Abbildung. Falls die Summe wohldefiniert ist, gilt:

$\mathbb{E}(\phi(X)) := \sum_{x \in W_X} \phi(x) \cdot \mathbb{P}(X = x)$

Wenn  $X : \Omega \rightarrow \mathbb{N}_0$ , kann man auch den Erwartungswert als

$\mathbb{E}(X) = \sum_{n=0}^{\infty} \mathbb{P}(X > n)$

schreiben.

## Erwartungswert - Stetige ZV

Sei  $X : \Omega \rightarrow \mathbb{R}$  eine stetige Zufallsvariable mit Dichte  $f$ . Sei  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  eine Abbildung, sodass  $\phi(X)$  eine Zufallsvariable ist. Dann gilt

$$\mathbb{E}(\phi(X)) = \int_{-\infty}^{\infty} \phi(x)f(x) dx,$$

solange das Integral wohldefiniert ist.

Sei  $X$  eine stetige ZV mit  $X \geq 0$  f.s., dann gilt:

$$\mathbb{E}(X) = \int_0^{\infty} \mathbb{P}(X > x) dx$$

## 3.1 Rechnen mit Erwartungswerten

**Linearität des Erwartungswertes:**

Seien  $X, Y : \Omega \rightarrow \mathbb{R}$  ZV mit  $\lambda \in \mathbb{R}$ , Falls die Erwartungswerte wohldefiniert sind, gilt:

$$\mathbb{E}(\lambda \cdot X + Y) = \lambda \cdot \mathbb{E}(X) + \mathbb{E}(Y)$$

Falls  $X, Y$  **unabhängig**, dann gilt auch:

$$\mathbb{E}(X \cdot Y) = \mathbb{E}(X) \cdot \mathbb{E}(Y)$$

Eine generellere Form wäre folgende Äquivalenz:

$X_1, X_2, \dots, X_n$  unabhängig

$\iff$

Für jede  $\phi_1 : \mathbb{R} \rightarrow \mathbb{R}, \dots, \phi_n : \mathbb{R} \rightarrow \mathbb{R}$  stückweise stetig, beschränkt gilt

$$\mathbb{E}(\phi_1(X_1) \cdots \phi_n(X_n)) = \mathbb{E}(\phi_1(X_1)) \cdots \mathbb{E}(\phi_n(X_n))$$

## 3.2 Ungleichungen

**Monotonie**

Seien  $X, Y$  ZV mit  $X \leq Y$  f.s., dann gilt:

$$\mathbb{E}(X) \leq \mathbb{E}(Y)$$

**Markov Ungleichung**

Sei  $X$  eine ZV und ferner  $g : X(\Omega) \rightarrow [0, +\infty)$  eine wachsende Funktion. Für jedes  $c \in \mathbb{R}$  mit  $g(c) > 0$  gilt dann

$$\mathbb{P}(X \geq c) \leq \frac{\mathbb{E}(g(X))}{g(c)}$$

*Einfache Version:*

Sei  $X$  eine ZV mit  $X \geq 0$  f.s., dann gilt für jedes  $t > 0$ :

$$\mathbb{P}(X \geq t) \leq \frac{\mathbb{E}(X)}{t}$$

**Chebyshev Ungleichung**

Sei  $Y$  eine ZV mit endlicher Varianz. Für jedes  $b > 0$  gilt dann

$$\mathbb{P}(|Y - \mathbb{E}(Y)| \geq b) \leq \frac{\text{Var}(Y)}{b^2}$$

**Jensen Ungleichung**

Sei  $X$  eine ZV und  $\phi : \mathbb{R} \rightarrow \mathbb{R}$  eine konvexe Funktion, dann gilt:

$$\phi(\mathbb{E}(X)) \leq \mathbb{E}(\phi(X))$$

## 3.3 Varianz

### Varianz

Sei  $X$  eine ZV, sodass  $\mathbb{E}(X^2) < \infty$ . Die **Varianz** von  $X$  ist definiert durch

$$\text{Var}(X) = \sigma_X^2 = \mathbb{E}((X - m)^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2$$

wobei  $m = \mathbb{E}(X)$ . Dabei wird  $\sigma_X$  als **Standardabweichung** von  $X$  bezeichnet und beschreibt den Erwartungswert für die Distanz von  $X$  zu  $\mathbb{E}(X)$ .

1. Sei  $X$  ein ZV, sodass  $\mathbb{E}(X^2) < \infty$  und  $\lambda \in \mathbb{R}$ :

$$\text{Var}(a \cdot X + b) = a^2 \cdot \text{Var}(X)$$

2. Seien  $X_1, \dots, X_n$  paarweise unabhängig. Dann gilt

$$\text{Var}(X_1 + \dots + X_n) = \text{Var}(X_1) + \dots + \text{Var}(X_n)$$

### Kovarianz

Seien  $X, Y$  ZV mit  $\mathbb{E}(X^2) < \infty, \mathbb{E}(Y^2) < \infty$ . Wir definieren die **Kovarianz** zwischen  $X$  und  $Y$  durch

$$\text{Cov}(X, Y) := \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

1.  $\text{Cov}(X, X) = \text{Var}(X)$
2.  $X, Y$  unabhängig  $\implies \text{Cov}(X, Y) = 0$  (Die Umkehrung ist falsch!)
3.  $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$

## 3.4 Bedingter Erwartungswert

Sei  $(\Omega, \mathcal{A}, \mathbb{P})$  ein diskreter Wahrscheinlichkeitsraum und  $X : \Omega \rightarrow \mathbb{R}$  eine Zufallsvariable.

Für ein beliebiges  $B \in \mathcal{A}, \mathbb{P}(B) > 0$  definieren wir den **bedingten Erwartungswert**  $X$  bedingt durch  $B$  als

$$\begin{aligned} \mathbb{E}(X | B) &= \frac{\mathbb{E}(\mathbb{1}_B X)}{\mathbb{P}(B)} = \sum_{x \in X(\Omega)} x \mathbb{P}(X = x | B) \\ &= \sum_{\omega \in \Omega} X(\omega) \mathbb{P}(\{\omega\} | B) \end{aligned}$$

**TODO: Beispielrechnung**

**Bedingter Erwartungswert als Zufallsvariable**

Wir betrachten eine Partition  $\mathcal{B} = (B_i)_{i \in I}$  von  $\Omega$  ( $B_i$  sind disjunkt und nichtleer,  $I$  abzählbar).

Dann definieren wir die **Zufallsvariable**

$$\mathbb{E}(X | \mathcal{B})(\omega) = \sum_{i \in I, \mathbb{P}(B_i) > 0} \mathbb{E}(X | B_i) \mathbb{1}_{B_i}(\omega)$$

1. **Intuition:** Die Information, die durch die Partition gegeben ist, ist, dass eines der  $B_i$  eintreten wird. Bei der Realisierung durch das Eintreten des Elementarereignisses  $\omega$  wird  $\mathbb{E}(X | B)$  zu dem  $\mathbb{E}(X | B_i)$  realisiert, bei welchem  $\omega \in B_i$ .

2. **Bemerkung:** Das  $\mathcal{B}$  hat in der Vorlesung 2 verschiedene Bedeutungen. Es wird als Variable für sowohl die Borelsche  $\sigma$ -Algebra als auch die Partition von  $\Omega$  verwendet.

**TODO: Beispielrechnung**

## 4 Mehrere Zufallsvariablen

### Gemeinsame Verteilung

Die **gemeinsame Verteilungsfunktion** von  $n$  Zufallsvariablen  $X_1, \dots, X_n$  (stetig oder diskret) ist die Abbildung  $F : \mathbb{R}^n \rightarrow [0, 1]$ ,

$$(x_1, \dots, x_n) \mapsto F(x_1, \dots, x_n) := \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n)$$

### 4.1 Diskreter Fall - Gewichtsfunktion

Für  $n$  diskrete ZV  $X_1, \dots, X_n$  definieren wir ihre **gemeinsame Gewichtsfunktion**  $p : \mathbb{R}^n \rightarrow [0, 1]$  durch

$$p(x_1, \dots, x_n) := \mathbb{P}(X_1 = x_1, \dots, X_n = x_n)$$

Aus der gemeinsamen Gewichtsfunktion  $p$  bekommt man die gemeinsame Verteilungsfunktion mit

$$\begin{aligned} F(x_1, \dots, x_n) &= \mathbb{P}(X_1 \leq x_1, \dots, X_n \leq x_n) \\ &= \sum_{y_1 \leq x_1, \dots, y_n \leq x_n} \mathbb{P}(X_1 = y_1, \dots, X_n = y_n) \\ &= \sum_{y_1 \leq x_1, \dots, y_n \leq x_n} p(y_1, \dots, y_n) \end{aligned}$$

### Konstruktion einer ZV

Seien  $X_1, \dots, X_n$  diskrete Zufallsvariablen in  $(\Omega, \mathcal{F}, \mathbb{P})$ , sodass  $X_1 \in W_1, \dots, X_n \in W_n$  f.s. für  $W_1, \dots, W_n \subset \mathbb{R}$  endlich oder abzählbar.

Für  $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$  beliebig, ist  $Z = \phi(X_1, \dots, X_n)$  eine diskrete Zufallsvariable mit  $Z \in W = \phi(W_1 \times \dots \times W_n)$  f.s. .

Die Gewichtsfunktion von  $Z$  ist gegeben durch  $p_Z : W \rightarrow [0, 1]$ :

$$p_Z(t) := \mathbb{P}(Z = t) = \sum_{\substack{x_1 \in W_1, \dots, x_n \in W_n \\ \phi(x_1, \dots, x_n) = t}} p(x_1, \dots, x_n)$$

1. Mit dem vorherigen Satz können wir aus der gemeinsamen Verteilung die **Randverteilung** einer Zufallsvariablen extrahieren (wegsummieren). Wir verwenden dafür einfach die Funktion

$$\phi(x_1, \dots, x_n) = x_i$$

2. Der Erwartungswert des Bildes der Funktion  $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$  ist

$$\mathbb{E}(\phi(X_1, \dots, X_n)) = \sum_{x_1, \dots, x_n} \phi(x_1, \dots, x_n) p(x_1, \dots, x_n)$$

3. Wir haben eine Äquivalenz:

$$\begin{aligned} X_1, \dots, X_n &\text{unabhängig} \\ \iff \\ \forall x_1 \in W_1, \dots, x_n \in W_n \\ p(x_1, \dots, x_n) &= \mathbb{P}(X_1 = x_1) \cdot \dots \cdot \mathbb{P}(X_n = x_n) \end{aligned}$$

## 4.2 Stetiger Fall - Gemeinsame Dichte

### Gemeinsame Dichte

Falls die gemeinsame Verteilungsfunktion von  $n$  Zufallsvariablen  $X_1, \dots, X_n$  sich schreiben lässt als

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_n \dots dt_1$$

für eine Funktion  $f: \mathbb{R}^n \rightarrow [0, \infty)$ , so heisst  $f(x_1, \dots, x_n)$  die **gemeinsame Dichte** von  $X_1, \dots, X_n$ .

- $f(x_1, \dots, x_n) \geq 0$ , und  $= 0$  ausserhalb von  $\mathcal{W}(X_1, \dots, X_n)$ .
- 

$$\mathbb{P}((X_1, \dots, X_n) \in A) = \int \dots \int_{(x_1, \dots, x_n) \in A} f(x_1, \dots, x_n) dx_n \dots dx_1$$

für  $A \subseteq \mathbb{R}^n$  beliebig.

- Haben  $X, Y$  die gemeinsame Verteilungsfunktion  $F_{X,Y}$ , so ist  $F_X: \mathbb{R} \rightarrow [0, 1]$ ,

$$F_X(x) := \mathbb{P}(X \leq x) = \mathbb{P}(X \leq x, Y \leq \infty) = \lim_{y \rightarrow \infty} F_{X,Y}(x, y)$$

die Verteilungsfunktion der *Randverteilung* von  $X$ . Analoges gilt für  $F_Y$ .

- Falls  $X, Y$  eine gemeinsame Dichte  $f(x, y)$  haben, so haben auch die Randverteilungen von  $X$  und  $Y$  Dichten  $f_X: \mathbb{R} \rightarrow [0, \infty)$  und  $F_Y: \mathbb{R} \rightarrow [0, \infty)$ .

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \text{ bzw. } f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx$$

Die **Dichtefunktion** einer Randverteilung (Randdichte) entsteht aus der gemeinsamen Dichtefunktion durch "Wegintegrieren" der anderen Variable(n).

Wenn  $X_1, \dots, X_n$  stetige ZV mit Dichten  $f_1, \dots, f_n$ , dann sind die folgenden Aussagen äquivalent:

- $X_1, \dots, X_n$  unabhängig
- $(X_1, \dots, X_n)$  ist stetig mit gemeinsamer Dichte

$$f(x_1, \dots, x_n) = f_1(x_1) \cdot \dots \cdot f_n(x_n)$$

- Für alle  $\phi_1: \mathbb{R} \rightarrow \mathbb{R}, \dots, \phi_n: \mathbb{R} \rightarrow \mathbb{R}$  die stückweise stetig und beschränkt sind, gilt

$$\mathbb{E}(\phi_1(X_1) \cdot \dots \cdot \phi_n(X_n)) = \mathbb{E}(\phi_1(X_1)) \cdot \dots \cdot \mathbb{E}(\phi_n(X_n))$$

## 4.3 Transformation von Zufallsvariablen

### Transformationssatz

Sei  $Z$  ein  $n$ -dimensionaler Zufallsvektor und  $g: (\mathbb{R}^n, \mathcal{B}^n) \rightarrow (\mathbb{R}^m, \mathcal{B}^m)$  eine messbare Abbildung. Dann ist

$$H(\omega) = g(Z(\omega))$$

ein  $m$ -dimensionaler Zufallsvariable und ferner gilt

$$\mathbb{P}(H \in A) = \mathbb{P}(X \in g^{-1}(A)).$$

Wenn  $g$  linear und umkehrbar (i.e.  $g(x) = m + Bx$  mit  $\det(B) \neq 0$ ) und unter Voraussetzung, dass die Verteilung von  $Z$  absolut stetig ist, dann ist  $H$  auch absolut stetig und es gilt:

$$f_H(x) = \frac{1}{|\det(B)|} f_Z(B^{-1}(x - m)).$$

### Beispielrechnung

$Z = (X, Y)$  2-dim Zufallsvektor. Wir wollen die Dichte von  $X + Y$  berechnen.

Man wäre versucht die Matrix  $B$  und den Vektor  $m$  wie folgt zu definieren:

$$\begin{aligned} B &= \begin{pmatrix} 1 & 1 \end{pmatrix} \text{ und } m = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ \implies g((X, Y)) &= \begin{pmatrix} 1 & 1 \end{pmatrix} \cdot \begin{pmatrix} X \\ Y \end{pmatrix} = X + Y \end{aligned}$$

Dann wäre aber  $B$  (und somit  $g$ ) nicht invertierbar! Deshalb wollen wir  $B$  so wählen, dass  $g((X, Y)) = (X, X + Y)$ :

$$\begin{aligned} \begin{pmatrix} X \\ X + Y \end{pmatrix} &= \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} X \\ Y \end{pmatrix} \\ \det(B) &= 1 \neq 0 \implies B \text{ invertierbar} \\ B^{-1} &= \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} \end{aligned}$$

Nach dem Transformationssatz gilt

$$\begin{aligned} f_{X, X+Y}(x, z) &= \frac{1}{|\det(B)|} f_{X,Y} \left( B^{-1} \cdot \begin{pmatrix} x \\ z \end{pmatrix} \right) \\ &= 1 \cdot f_{X,Y} \left( \begin{pmatrix} 1 & 0 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} x \\ z \end{pmatrix} \right) \\ &= f_{X,Y}(x, z - x) \end{aligned}$$

Aus der gemeinsamen Dichte  $f_{X, X+Y}$  können wir die Dichte  $f_{X+Y}$  bestimmen.

$$\begin{aligned} f_{X+Y}(z) &= \int_{-\infty}^{\infty} f_{X, X+Y}(x, z) dx \\ &= \int_{-\infty}^{\infty} f_{X,Y}(x, z - x) dx \end{aligned}$$

Falls  $X$  und  $Y$  unabhängig

$$= \int_{-\infty}^{\infty} f_X(x) \cdot f_Y(z - x) dx$$

### Transformation von Zufallsvariablen

Sei  $\phi: \mathbb{R}^n \rightarrow \mathbb{R}$  eine Abbildung und  $X_1, \dots, X_n$  ZV mit gemeinsamer Dichte  $f$ . Dann lässt sich  $\mathbb{E}(Z)$  für die Zufallsvariable  $Z = \phi(X_1, \dots, X_n)$  mit

$$\mathbb{E}(Z) = \int_{\mathbb{R}^n} \dots \int \phi(x_1, \dots, x_n) \cdot f(x_1, \dots, x_n) dx_n \dots dx_1$$

berechnen.

### Beispielrechnung

Wir können diese Art den Erwartungswert zu berechnen nutzen, um die Dichte einer transformierten Zufallsvariable zu berechnen.

Seien  $X$  und  $Y$  zwei Zufallsvariablen mit gemeinsamer Dichtefunktion

$$f(x, y) = \begin{cases} \frac{1}{x^2 y^2} & \text{für } x \geq 1, y \geq 1 \\ 0 & \text{sonst.} \end{cases}$$

Bestimme die Dichtefunktion  $f_V$  der Zufallsvariable  $V = XY$ .

Wir definieren  $\phi(x, y) = xy$  und berechnen

$$\begin{aligned} \mathbb{E}(V) &= \mathbb{E}(\phi(X, Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \phi(x, y) f(x, y) dx dy \\ &= \int_1^{\infty} \int_1^{\infty} \phi(x, y) \frac{1}{x^2 y^2} dx dy \\ \text{Substitution } v &= xy, dv = y dx \\ &= \int_1^{\infty} \int_y^{\infty} \frac{v}{y} \frac{1}{v^2} dv dy \end{aligned}$$

$$\begin{aligned} A &= \{(v, y) \in \mathbb{R}^2 \mid 1 \leq y < \infty, y \leq v < \infty\} \\ &= \{(v, y) \in \mathbb{R}^2 \mid 1 \leq y \leq v, 1 \leq v < \infty\} \end{aligned}$$

Zeichnung hilft ;)

$$\begin{aligned} &= \int_1^{\infty} \int_1^v \frac{1}{vy} dy dv \\ &= \int_1^{\infty} \frac{\ln(v)}{v} dv \\ &= \int_{-\infty}^{\infty} v \cdot \frac{\ln(v)}{v^2} \mathbb{1}_{v \in [1, \infty)} dv \end{aligned}$$

$$\implies f_V(t) = \frac{\ln(v)}{v^2} \mathbb{1}_{v \in [1, \infty)}$$

## 5 Konvergenz in Wahrscheinlichkeitsräumen

### Unabhängigkeit einer Folge und iid./uiv.

Eine Folge von ZV  $X_1, X_2, \dots$  ist unabhängig, wenn  $X_1, \dots, X_n$  unabhängig ( $\forall n \in \mathbb{N}$ , nach der Definition in 2.1). Sie ist zudem **uiv./iid.**, falls  $F_{X_i} = F_{X_j}, \forall i, j \in \mathbb{N}$ .

In einem Wahrscheinlichkeitsraum können wir für eine Folge von Zufallsvariablen  $X_1, X_2, \dots$  und einer ZV  $Z$  zwischen 3 Arten von Konvergenz unterscheiden:

1. **schwache Konvergenz / Konvergenz in Verteilung**

Wir definieren  $X_n \xrightarrow{d} Z$  ( $d$  for distribution) als

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n \leq x) = \lim_{n \rightarrow \infty} F_{X_n}(x) = F_Z(x) = \mathbb{P}(Z \leq x)$$

für jede Stetigkeitsstelle  $x \in \mathbb{R}$  von  $F_Z$ .

2. **Konvergenz in Wahrscheinlichkeit**

Wir definieren  $X_n \xrightarrow{\mathbb{P}} Z$  als

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - Z| > \varepsilon) = 0$$

3. **Fast-sichere Konvergenz**

Wir definieren  $X_n \xrightarrow{\text{f.s.}} Z$  als

$$\mathbb{P}(\{\omega \in \Omega \mid \lim_{n \rightarrow \infty} X_n(\omega) = Z(\omega)\}) = 1$$

Wir haben dann auch

$$X_n \xrightarrow{\text{f.s.}} Z \implies X_n \xrightarrow{\mathbb{P}} Z \implies X_n \xrightarrow{d} Z$$

Die Umkehrung der Implikationen gilt nicht, wie folgende Beispiele zeigen:

1.  $X_n \xrightarrow{d} Z \not\Rightarrow X_n \xrightarrow{\mathbb{P}} Z$

Sei  $\Omega = \{0, 1\}$  und für alle  $n \in \mathbb{N}$

$$\mathbb{P}(X_n = 0) = \mathbb{P}(X_n = 1) = \frac{1}{2}, \quad X_n(\omega) = \begin{cases} 0 & \omega = 0 \\ 1 & \omega = 1 \end{cases}$$

und

$$\mathbb{P}(Z = 0) = \mathbb{P}(Z = 1) = \frac{1}{2}, \quad Z(\omega) = \begin{cases} 1 & \omega = 0 \\ 0 & \omega = 1 \end{cases}$$

Aus  $F_{X_n} = F_Z$  folgt direkt  $X_n \xrightarrow{d} Z$ .

Da aber  $|X_n(\omega) - Z(\omega)| = 1, \forall \omega \in \Omega$  und demzufolge  $\lim_{n \rightarrow \infty} \mathbb{P}(|X_n - Z| > \varepsilon) \not\rightarrow 0$  für  $n \rightarrow \infty$ , gilt

$$X_n \not\xrightarrow{\mathbb{P}} Z$$

2.  $X_n \xrightarrow{\mathbb{P}} Z \not\Rightarrow X_n \xrightarrow{\text{f.s.}} Z$

Wir betrachten den Wahrscheinlichkeitsraum  $([0, 1], \mathcal{B}, \mathbb{P})$ . Für ein beliebiges  $n \in \mathbb{N}$  sei  $k = \lfloor \log_2(n) \rfloor$  und  $j \in \{0, \dots, 2^k - 1\}$ , sodass  $n = 2^k + j$ .

Dann definieren wir

$$X_n(\omega) = \mathbb{1}_{\left[\frac{j}{2^k}, \frac{j+1}{2^k}\right]}(\omega).$$

und

$$Z(\omega) = 0 \quad \forall \omega \in \Omega = [0, 1]$$

Zur Visualisierung würde die Folge so aussehen

$$X_1 = \mathbb{1}_{[0,1]}, X_2 = \mathbb{1}_{[0, \frac{1}{2}]}, X_3 = \mathbb{1}_{[\frac{1}{2}, 1]}, X_4 = \mathbb{1}_{[0, \frac{1}{4}]} \text{ etc.}$$

Wir hätten dann

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} \mathbb{P}(|X_n - Z| > \varepsilon) = 0 \implies X_n \xrightarrow{\mathbb{P}} Z$$

Aber für jedes  $\omega \in [0, 1]$  finden wir unendlich viele  $X_n$  mit  $X_n(\omega) = 1$  und deshalb

$$\mathbb{P}(\{\omega \in [0, 1] \mid \lim_{n \rightarrow \infty} X_n(\omega) = Z(\omega)\}) = 0 \implies X_n \not\xrightarrow{\text{f.s.}} Z$$

5.1 Gesetz der grossen Zahlen

**starkes Gesetz der grossen Zahlen**

Sei  $X_1, X_2, \dots$  eine Folge von uiv. Zufallsvariablen. Sei  $\mathbb{E}(|X_1|) < \infty$  und  $\mu = \mathbb{E}(X_1)$ . Für

$$\bar{X}_n = \frac{1}{n} S_n = \frac{1}{n} \sum_{i=1}^n X_i$$

gilt dann

$$\bar{X}_n \longrightarrow \mu \text{ f.s.}$$

Dies ist eine fast-sichere Konvergenz.

**schwaches Gesetz der grossen Zahlen**

Sei  $X_1, X_2, \dots$  eine Folge von paarweise unkorrelierten Zufallsvariablen, die alle den gleichen Erwartungswert  $\mathbb{E}(X_i) = \mu$  und die gleiche Varianz  $\text{Var}(X_i) = \sigma^2$  haben. Sei

$$\bar{X}_n = \frac{1}{n} S_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Dann konvergiert  $\bar{X}_n$  für  $n \rightarrow \infty$  in Wahrscheinlichkeit gegen  $\mu = \mathbb{E}(X_i)$ , d.h.

$$\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} \mathbb{P}(|\bar{X}_n - \mu| > \varepsilon) = 0 \text{ i.e. } \bar{X}_n \xrightarrow{\mathbb{P}} \mu$$

**Bemerkung:**

Zur Erinnerung:

$$X_i, X_j \text{ unkorreliert} \iff \text{Cov}(X_i, X_j) = 0$$

Wir haben auch

$$X_i, X_j \text{ unabhängig} \implies X_i, X_j \text{ unkorreliert}$$

5.2 Zentraler Grenzwertsatz

**Zentraler Grenzwertsatz**

Sei  $(X_n)_{n \in \mathbb{N}}$  eine Folge von iid. Zufallsvariablen mit  $\mathbb{E}(X_i) = \mu < \infty$  und  $\text{Var}(X_i) = \sigma^2 < \infty$ . Dann gilt

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{S_n - n\mu}{\sigma\sqrt{n}} \leq x\right) = \Phi(x) \quad \forall x \in \mathbb{R}$$

also

$$\frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

**Bemerkungen:**

Man verwendet auch oft die Form für  $\bar{X}_n = \frac{1}{n} S_n$  als

$$\frac{X_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1)$$

5

beziehungsweise

$$S_n \xrightarrow{d} \mathcal{N}(n\mu, n\sigma^2) \text{ und } \bar{X}_n \xrightarrow{d} \mathcal{N}\left(\mu, \frac{1}{n}\sigma^2\right)$$

**Beispielrechnung:**

Seien  $(X_i)_{i \geq 1}, (Y_i)_{i \geq 1}$  und  $(Z_i)_{i \geq 1}$  Folgen von iid. ZV mit

$$\mathbb{P}(X_1 = 1) = \mathbb{P}(X_1 = -1) = \frac{1}{2}$$

und analog für  $Y_1$  und  $Z_1$ . Wir definieren

$$S_n^{(x)} := \sum_{i=1}^n X_i, \quad S_n^{(y)} := \sum_{i=1}^n Y_i, \quad S_n^{(z)} := \sum_{i=1}^n Z_i$$

Die Folge  $\left((S_n^{(x)}, S_n^{(y)}, S_n^{(z)})\right)_{n \geq 1}$  wird zufällige Irrfahrt in  $\mathbb{Z}^3$  genannt. Sei  $\alpha > \frac{1}{2}$ . Zeige, dass

$$\mathbb{P}\left(\left\|\left(S_n^{(x)}, S_n^{(y)}, S_n^{(z)}\right)\right\|_2 \leq n^\alpha\right) \longrightarrow 1 \text{ für } n \rightarrow \infty,$$

wobei  $\|(x, y, z)\|_2 := \sqrt{x^2 + y^2 + z^2}$  die euklidische Norm ist.

*Schritt 1:* Für alle  $\alpha > 1/2$  zeigen wir  $\mathbb{P}(|S_n^{(x)}| \leq n^\alpha) \xrightarrow{n \rightarrow \infty} 1$ .

Da  $\mathbb{E}(X_i) = 0$  und  $\text{Var}(X_i) = 1$  folgt für  $a \in \mathbb{R}$  beliebig per ZGS

$$\mathbb{P}\left(S_n^{(x)} \leq a\sqrt{n}\right) = \mathbb{P}\left(\frac{S_n^{(x)}}{\sqrt{n}} \leq a\right) \xrightarrow{n \rightarrow \infty} \Phi(a)$$

und somit auch

$$\mathbb{P}\left(|S_n^{(x)}| \leq a\sqrt{n}\right) = \mathbb{P}\left(S_n^{(x)} \leq a\sqrt{n}\right) - \mathbb{P}\left(S_n^{(x)} \leq -a\sqrt{n}\right) \xrightarrow{n \rightarrow \infty} \Phi(a) - \Phi(-a) = 2\Phi(a) - 1$$

Sei  $\alpha = 1/2 + \beta, \beta > 0$ . Dann instanzieren wir mit  $a = n^\beta$ .

$$\mathbb{P}\left(|S_n^{(x)}| \leq n^\alpha\right) = \mathbb{P}\left(|S_n^{(x)}| \leq n^\beta \sqrt{n}\right) \longrightarrow \lim_{n \rightarrow \infty} (2\Phi(n^\beta) - 1) = 1$$

Dies gilt analog für  $S_n^{(y)}$  und  $S_n^{(z)}$ .

*Schritt 2:*  $\forall \alpha > 1/2, \mathbb{P}\left(\left\|\left(S_n^{(x)}, S_n^{(y)}, S_n^{(z)}\right)\right\|_2 \leq n^\alpha\right) \xrightarrow{n \rightarrow \infty} 1$ .

Sei  $\alpha' \in (1/2, \alpha)$ . Dann folgt

$$\begin{aligned} &\left\{|S_n^{(x)}| \leq n^{\alpha'} \wedge |S_n^{(y)}| \leq n^{\alpha'} \wedge |S_n^{(z)}| \leq n^{\alpha'}\right\} \\ &\subseteq \left\{\left\|\left(S_n^{(x)}, S_n^{(y)}, S_n^{(z)}\right)\right\|_2 \leq \sqrt{3} \cdot n^{\alpha'}\right\} \end{aligned}$$

Da  $n^\alpha \geq \sqrt{3}n^{\alpha'}$  für grosse  $n$ , folgt

$$\begin{aligned} &\lim_{n \rightarrow \infty} \mathbb{P}\left(\left\|\left(S_n^{(x)}, S_n^{(y)}, S_n^{(z)}\right)\right\|_2 \leq n^\alpha\right) \\ &\geq \lim_{n \rightarrow \infty} \mathbb{P}\left(\left\|\left(S_n^{(x)}, S_n^{(y)}, S_n^{(z)}\right)\right\|_2 \leq \sqrt{3} \cdot n^{\alpha'}\right) \\ &\geq \lim_{n \rightarrow \infty} \mathbb{P}\left(|S_n^{(x)}| \leq n^{\alpha'}, |S_n^{(y)}| \leq n^{\alpha'}, |S_n^{(z)}| \leq n^{\alpha'}\right) = 1 \end{aligned}$$